


# OneClassSVM



- 算法思想

- 找到一个超球面，球面中心为 $a$ , 半径为 $R$  使得所有正常样本在球面内，同时球面尽可能的小

此时目标函数与约束条件为：

$$\begin{aligned} \min_{R,a} R^2 \\ s.t. \quad \|\mathbf{x}_i - \mathbf{a}\|^2 \leq R^2 \end{aligned}$$

- 由于一般情况下不能通过球面将正常样本和非正常样本完全分开，因此如果球面内包含所有正常样本，则可能包含更多的非正常样本。因此给样本点  $x_i$  引入松弛条件  $\xi_i$ , 允许部分正常样本点在球面之外，同时对松弛距离在目标函数加入惩罚项， $C$ 为惩罚系数, $C>0$  ,根据需要人为设定。

此时目标函数与约束条件为：

$$\begin{aligned} \min_{R,a} R^2 + C \sum_i \xi_i \\ s.t. \quad \|\mathbf{x}_i - \mathbf{a}\|^2 \leq R^2 + \xi_i, \quad \xi_i \geq 0 \quad \forall i \end{aligned}$$

- 求解步骤

1. 通过拉格朗日乘子法转化将条件极值转化为无约束极值

拉格朗日函数如下：

$$\begin{aligned} L(R, \mathbf{a}, \alpha_i, \gamma_i, \xi_i) = & R^2 + C \sum_i \xi_i \\ & - \sum_i \alpha_i \left\{ R^2 + \xi_i - \left( \|\mathbf{x}_i\|^2 - 2\mathbf{a} \cdot \mathbf{x}_i + \|\mathbf{a}\|^2 \right) \right\} - \sum \gamma_i \xi_i \end{aligned}$$

$\alpha_i \geq 0$  ,  $\gamma_i \geq 0$  ,对拉格朗日函数求最大值的条件等价于原条件极值的条件。此时原问题转化为先对拉格朗日函数求最大值再求最小值即：

$$\min_{R,a,\xi} \max_{\alpha,\gamma} L \quad (1)$$

2. 转化为对偶问题求解

$$\min_{R,a,\xi} \max_{\alpha,\gamma} L = \max_{\alpha,\gamma} \min_{R,a,\xi} L \quad (2)$$

根据  $\min_{R,a,\xi} L$  求偏导

$$\begin{aligned} \frac{\partial L}{\partial R} = 0 : \quad & \sum_i \alpha_i = 1 \\ \frac{\partial L}{\partial \mathbf{a}} = 0 : \quad & \mathbf{a} = \frac{\sum_i \alpha_i \mathbf{x}_i}{\sum_i \alpha_i} = \sum_i \alpha_i \mathbf{x}_i \\ \frac{\partial L}{\partial \xi_i} = 0 : \quad & C - \alpha_i - \gamma_i = 0 \end{aligned}$$

将等式代入  $L$  得到:

$$L = \sum_i \alpha_i (\mathbf{x}_i \cdot \mathbf{x}_i) - \sum_{i,j} \alpha_i \alpha_j (\mathbf{x}_i \cdot \mathbf{x}_j)$$

此时目标函数和约束条件如下: 约束条件由求偏导的第三条等式可得

$$\max_{\alpha} \sum_i \alpha_i (\mathbf{x}_i \cdot \mathbf{x}_i) - \sum_{i,j} \alpha_i \alpha_j (\mathbf{x}_i \cdot \mathbf{x}_j) \text{ subject to } 0 \leq \alpha_i \leq C$$

此时仅有  $\alpha$  未知 可根据二次规划求解  $\alpha$ , 然后根据  $\alpha$  和求偏导第三条等式得到  $\gamma$ , 根据  $\alpha$  和第二条求偏导等式得到  $a$

根据KTT条件即原来的约束条件乘以拉格朗日乘数等于零即

$$\begin{aligned} \gamma_i \xi_i &= 0 \\ ||x_i - a||^2 - R^2 - \xi_i &= 0 \end{aligned} \quad (3)$$

分别得到  $\xi_i$  和  $R$

- 最终结果即为超球面  $(x - a)^2 \leq R^2$

分类器对样本  $x$  的判断为

$$f(x) = \text{sign}(R^2 - (x - a)^2) \quad (4)$$

- 核函数定义

定义两个向量的内积函数  $K(x, z)$

此时存在函数  $\phi$  使得  $\phi(x)$  和  $\phi(z)$  的内积  $\phi(x) \cdot \phi(z) = K(x, z)$ , 同一个核函数  $K$  可能对应多个映射函数  $\phi$

$\phi$  一般将向量  $x$  映射到高维空间, 或对向量  $x$  的每个维度进行非线性变换, 由于目标函数可以转化为关于测试数据  $\bar{x}$  的项都是和已知样本  $x_i$  的内积项, 因此仅考虑给出核函数  $K$  无需寻找对于的映射函数  $\phi$

- 定义核函数之后的超平面球面参数求解过程

### 1. 求解 $\alpha_i$

根据最终化简的二次优化问题

$$\max_{\alpha} \sum_i \alpha_i (\mathbf{x}_i \cdot \mathbf{x}_i) - \sum_{i,j} \alpha_i \alpha_j (\mathbf{x}_i \cdot \mathbf{x}_j) \text{ subject to } 0 \leq \alpha_i \leq C$$

将目标函数中的  $x_i \cdot x_i$  和  $x_i \cdot x_j$  替换为  $K(x_i, x_i)$  和  $K(x_i, x_j)$  求解  $\alpha_i$ ，进而根据偏导第三条方程求得求得  $\gamma$

### 2. 根第二条方程替换 $a$ 为 $\sum_i \alpha_i x_i$

### 3. 因此判别函数为

$$f(x) = \text{sign}(R^2 - (x - \sum_i \alpha_i x_i)^2) \quad (6)$$

$$f(x) = \text{sign}(R^2 - x^2 + 2 \sum_i x x_i + (\sum_i \alpha_i x_i)^2)$$

$$f(x) = \text{sign}(R^2 - K(x, x) + 2 \sum_i K(x, x_i) + \sum_i \sum_j \alpha_i \alpha_j K(x_i, x_j))$$

- 常见的核函数

#### 线性核 (Linear Kernel)

$$k(x, y) = x^T y + c$$

#### 多项式核 (Polynomial Kernel)

$$k(x, y) = (x^T y + c)^d$$

#### 径向基核函数 (Radial Basis Function)

$$k(x, y) = \exp(-\gamma \|x - y\|^2)$$

也叫高斯核 (Gaussian Kernel)，因为可以看成如下核函数的一个特形式：

$$k(x, y) = \exp\left(-\frac{\|x - y\|^2}{2\sigma^2}\right)$$

对于RBF核函数  $\gamma \rightarrow +\infty$  任意两点的距离越趋于0，越不可分。 $\gamma \rightarrow -\infty$  任意两点距离趋于无穷，太稀疏，

$\gamma \rightarrow 0$ ，任意两点距离趋于1。